

LawPath 에이전트 시험 결과 보고서

자기 성찰 및 검증 흐름의 시험 근거와 측정 계획

본 보고서는 LawPath의 입력 판단, 도구 호출, 근거 검증, 안전한 종료 흐름을 시험한 결과를 정리한다. 비교 전 기준은 31edb7f, 비교 후 기준은 현재 BO 브랜치의 8fa7627로 고정했다. 전체 pytest 결과와 함께, 외부 서비스에 연결하지 않는 동일한 100건 로컬 모의 시험을 두 기준에 적용해 전후 지표를 산정했다.

1 시험 목적

동일한 법률 질의 흐름에서 입력 부족 감지, 도구 선택, 도구 결과 검증, 근거 기반 응답 및 실패 처리의 동작을 확인한다. 특히 근거 부족 시 보완 검색, 검색 전 보완 질문, 검색되지 않은 근거 인용 차단이 안전하게 작동하는지 검증한다.

2 시험 기준과 실행 환경

구분	기준	설명
비교 전	31edb7f	근거 부족 시 MCP 보완 검색을 도입한 d01d96b 직전 상태
비교 후	8fa7627	현재 BO 브랜치 HEAD. 입력 판단, 재시도, 근거 검증 및 폴백이 포함된 상태
실행 명령	pytest -q --disable-warnings	GitHub Actions의 pytest 실행과 같은 전체 테스트 기준
실행 환경	Windows PowerShell, Python 3.12 가상환경	프로젝트 루트와 별도 Git worktree에서 각각 실행

3 시험 데이터와 확인 항목

유형	현재 자동 시험 근거	확인 항목
정상 법률 질의	test_legal_question_service, test_legal_mcp_runtime	카테고리별 검색과 Evidence 기반 응답 생성

유형	현재 자동 시험 근거	확인 항목
입력 정보 부족	test_intake_agent, test_legal_question_service	검색 전 needs_clarification 및 후속 질문 반환
도구 선택과 호출 한도	test_legal_mcp_runtime, test_legal_mcp_client	프로필별 도구 순서, trace, 최대 3회 호출
MCP 실패와 빈 결과	test_legal_search_api, test_legal_mcp_runtime	실패 전파, no_results, 근거 없는 답변 방지
응답 근거 불일치	test_llm_answer_service, test_answer_agent	검색되지 않은 evidence id 차단 및 템플릿 폴백
SSE 및 중복 요청	test_agent_stream, test_mock_api	실행 이벤트, 재연결, idempotency 계 약

4 오류 감지 기준

- 할루시네이션: AnswerDraft의 used_evidence_ids가 실제 검색된 Evidence ID 집합의 부분집합이 아니면 감지한다.
- 도구 선택 오류: AgentProfile의 allowed_tools에 없는 도구이거나 카테고리별 고정 검색 순서를 벗어나면 정책 검증에서 차단한다.
- 파라미터 또는 입력 정보 부족: IntakeResult가 needs_clarification이면 MCP 호출 전에 중단하고 최대 3개의 보완 질문을 반환한다.
- 응답 불일치: 최종 응답이 검색된 Evidence와 연결되지 않거나 인용 ID 검증에 실패하면 LLM 결과를 사용하지 않는다.
- 반복 초과: Runtime의 도구 호출 수가 최대 3회를 넘으려 하면 실행 오류로 종료한다.

5 오류별 대응과 자기 성찰 흐름

오류	감지와 수정 전략	재시도 또는 종료 조건
입력 판단 계약 오류	구조화 출력 재요청	시간 제한 내 최대 1회 재시도 후 IntakeAssessmentError
입력 정보 부족	도구 호출을 생략하고 보완 질문	needs_clarification과 stopped로 종료
MCP 도구 실패 또는 형식 오류	오류를 RuntimeError로 전파	run.failed와 일반화된 오류 안내
검색 결과 0건	근거 없는 내용 생성 금지	no_results로 종료

오류	감지와 수정 전략	재시도 또는 종료 조건
근거 3건 미만	가능한 Evidence는 유지하고 주의사항 추가	insufficient_evidence로 종료
검색 외 근거 인용	LLM 초안을 폐기하고 AnswerAgent 사용	재시도 없이 안전한 폴백

6 실제 pytest와 100건 모의 시험 결과

기준	실행 결과	해석
비교 후 8fa7627	243 passed, 4 skipped, 1 warning, 19.62s	전체 pytest가 exit code 0으로 정상 종료
비교 전 31edb7f	105개 수집, 진행 표시 100% 후 종료 지연	테스트 프로세스를 중단했으므로 성공률 수치로 사용하지 않음

태스크 완료율, 도구 선택 정확도, 응답 일관성, 평균 재시행 횟수는 *pytest* 통과율과 다른 측정값이다. 아래 수치는 동일한 가짜 MCP 응답을 주입한 로컬 Runtime 시험의 결과이며, 실제 법률 DB, 실제 LLM, 네트워크 지연 또는 법률 근거의 품질을 측정한 값이 아니다.

지표	적용 전	적용 후	산식과 측정 상태
태스크 완료율	75% (75/100)	100% (100/100)	기대 종료 상태와 Evidence 수를 충족한 건수 ÷ 100
도구 선택 정확도	0% (0/95)	100% (95/95)	현 설계의 분야별 다중 검색 순서와 실제 selector 비교. 호출 한도 초과 5건 제외
응답 일관성	75% (75/100)	100% (100/100)	종료 사유, Evidence 수, 안전할 오류 처리가 케이스 기대값과 일치한 비율
평균 동일 도구 재시도	0.0회	0.0회	Runtime에는 실패한 같은 도구의 자동 재시도가 없으므로 0.0회. 다른 검색 도구 호출은 재시도로 계산하지 않음

7 프롬프트와 파라미터 조정 이력

변경 커밋	발견 문제	변경 내용	검증 근거
d01d96b	근거가 부족한 검색 결과	MCP 보완 검색과 도구 선택 순서 보강	Runtime의 추가 검색 및 Evidence 수 테스트
9628926	모호한 질문과 LLM 출력 형식	LLM 기반 입력 충분성 판단, 구조화 출력 재시도, 인용 ID 검증	입력 판단과 LLM 답변 서비스 테스트
33436fc	입력 체크의 세분화 필요	입력 판단 체크와 선택 저장 대화 흐름 추가	입력 판단 및 API 계약 테스트

8 재실행과 검증 계획

이번 보고서의 전후 지표는 동일한 100건 가짜 MCP 응답을 두 기준 커밋에 적용해 산정했다. 프로젝트에는 tests/run_lawpath_100.py와 별도의 100건 평가 데이터셋도 있으나, 이 도구는 현재 구현에서 추가되었고 실제 서버 연결을 포함한다. 따라서 본 모의 결과와 실제 서비스 품질 결과를 혼용하지 않는다.

- 31edb7f와 8fa7627에 같은 시험 러너, 같은 100건, 같은 가짜 MCP 응답을 적용했다.
- 각 실행의 request id, tool_selected와 tool_completed trace, termination_reason, used_evidence_ids를 원본 로그로 보관한다.
- 정상 요청, 정보 부족, 빈 결과, 타임아웃, 인증 실패, 상충 지시를 동일한 비율로 포함한다.
- 자동 판정 후 법률 근거의 관련성, 인용 정확성, 제한사항 안내는 사람 검토로 별도 기록한다.
- 프로세스 종료 지연이 재현되면 해당 현상을 별도 결함으로 등록하고, 완료 지표와 분리해 보고한다.